

OCI Enterprise AI com Hermes Agent

Crie seu super agente de AI utilizando Hermes Agent e Soluções Oracle Cloud |
TDC Florianópolis

Rafael Roberto Dias

Principal AI Engineer — Oracle

90 minutos: contexto curto, prática com margem

ROTEIRO

00–15

CONTEXTO

OCI Enterprise AI +
Hermes

15–25

STACK

Resource Manager em
ORD

25–40

CREDENCIAIS

OCI API key + BotFather

40–75

HANDS-ON

VM, Hermes e Telegram

75–90

MARGEM

Dúvidas, contingência e
fechamento

Resultado: bot no Telegram chamando um modelo OCI por meio do Hermes Agent.

Região padrão: US Midwest (Chicago) · us-chicago-1 · ORD



OCI Enterprise AI conecta modelos, agentes e controles

PLATAFORMA OCI GENERATIVE AI

MODELOS

Hosted, open-weight e importáveis

ACESSO

Playground, APIs nativas e OpenAI-compatible

AGENTES

Responses API, tools, memory e projects

DADOS

Embeddings, rerank e vector stores

GOVERNANÇA

IAM, private endpoints, guardrails e audit

OPERAÇÃO

Regiões, endpoints, observabilidade e custo

Avaliar, integrar, governar e operar IA na mesma plataforma.

O catálogo é uma matriz, não uma lista

MODELOS EM OCI

CHAT · RACIOCÍNIO

Cohere Command A
Gemini 2.5
Llama 4 / 3.3

OPEN-WEIGHT

OpenAI gpt-oss
Meta Llama
Mistral / Qwen / Gemma

MULTIMODAL

Gemini 2.5
Llama 4
modelos com visão

RETRIEVAL

Cohere Embed
Cohere Rerank
vetores + relevância

AGENTIC

Responses API
OCI GenAI Agents
function / MCP calling

IMPORTÁVEIS

DeepSeek · Phi · Kimi
Nemotron · Whisper · GLM
entre famílias suportadas

Cruze sempre: modelo × região/modo × superfície de agent.

Catálogo de modelos por provedor (1/2)

MATERIAL DO WORKSHOP · SUJEITO A REGIÃO E SUPERFÍCIE

OPENAI*

o-series · Whisper · GPT
* Marketplace US

GOOGLE

Gemini · Gemma

META

Llama open-source models

DEEPSEEK

DeepSeek models

MICROSOFT

Phi

MISTRAL

Mistral · Devstral · Mixtral

A oferta comercial e a superfície disponível podem variar por região.

Catálogo de modelos por provedor (2/2)

MATERIAL DO WORKSHOP · SUJEITO A REGIÃO E SUPERFÍCIE

xAI

Grok

COHERE

Command A · R/R+ · Embed · Rerank

ALIBABA

Qwen · Qwen Image · Q · Embed

MOONSHOT

Kimi

MINIMAX

MiniMax

NVIDIA + Z.AI

Nemotron · GLM

Confirme modelo × região × modo × API 24 horas antes do workshop.

ORD é a região padrão — mas o catálogo é um snapshot

SNAPSHOT · 22 JUL 2026

FAMÍLIA	EXEMPLOS	MODO / NOTA
gpt-oss	120b · 20b	on-demand; opções em DAC
Gemini 2.5	Pro · Flash · Flash-Lite	on-demand em ORD
Llama	4 Maverick · 4 Scout · 3.3 70B	on-demand; parte em DAC
Cohere	Command · Embed · Rerank	chat e retrieval
xAI Grok	família disponível	ver superfície e data path

Confirme disponibilidade, status e superfície 24h antes.



Quatro portas de entrada para consumir modelos

FORMAS DE CONSUMO

1 Playground

Explorar prompts, parâmetros e modelos no browser.

2 API nativa

Chat, embeddings, rerank e inferência com IAM.

3 Responses API

Interface OpenAI-compatible, tools e estado opcional.

4 GenAI Agents

Runtime gerenciado para RAG, tools e integrações.

A lista de modelos suportados muda entre essas superfícies.

Contratação: on-demand ou Dedicated AI Cluster?

MODALIDADES DE CONSUMO

ON-DEMAND

Capacidade compartilhada e gerenciada

Sem provisionar cluster

Cobrança por inferência

Melhor para trial, POC e evals

Throttling dinâmico

DEDICATED AI CLUSTER

GPU dedicada e performance previsível

Hosting cluster + endpoint

Cobrança por unit-hour

Pretrained, fine-tuned e imported models

SLO, isolamento e throughput

DAC pretrained/fine-tuned: compromisso mínimo documentado de 744 unit-hours. Imported models: sem esse mínimo, mas com consumo do cluster cobrado.

Escolha por eval — não por ranking genérico

DECISÃO

01 Tool selection

Escolhe a ferramenta e a ordem corretas?

02 Contrato

JSON/schema estável para parser?

03 Segurança

Resiste a injeção e minimiza dados?

04 Performance

Latência, throughput e contexto servem ao SLO?

05 Economia

Preço + modo + operação cabem no caso?

Comece com um eval pequeno, representativo e automatizável.

Hermes é um runtime de agente aberto — não um modelo

NOUS RESEARCH · OPEN SOURCE

RUNTIME AGENTIC

Loop de raciocínio, tools e aprovações

PROVIDERS

OCI via endpoint OpenAI-compatible

SKILLS

Procedimentos reutilizáveis e aprendizagem

MEMÓRIA

Sessões e contexto persistente

CANAIS

Telegram, Discord, Slack e outros

OPERAÇÃO

CLI, gateway, doctor e serviço

O mesmo agente funciona no terminal e no Telegram, com suas ferramentas.

Hermes foi escolhido para maximizar o hands-on

DECISÃO DO WORKSHOP

A · TIME-TO-VALUE

Gateway, tools, memory e skills no mesmo pacote

Cloud-init automatiza a instalação

Menos integrações ao vivo

RECOMENDADO

B · OCI-FRIENDLY

Provider customizado

Endpoint OpenAI-compatible

Troca de modelo sem reescrever o agente

PORTÁVEL

C · TELEGRAM READY

Gateway nativo

Long polling de saída


Sem domínio, TLS ou webhook

BAIXA FRICÇÃO

Em 60 minutos práticos, o foco fica no agente — não em construir o runtime.

A arquitetura separa canal, runtime e modelo

ARQUITETURA DO LABORATÓRIO · ORD



Terraform cria rede, VM e policy; API key e token entram depois e não ficam no state.

Segurança do laboratório também é defesa em camadas

CONTROLES DO WORKSHOP

1

IAM + compartment

menor privilégio para modelo e infraestrutura

2

Rede + VM

SSH na porta 22; Hermes não é exposto

3

Segredos

API key e bot token fora do Terraform state

4

Telegram

allowlist ou pairing; nunca liberar todos

5

Audit + cleanup


logs, validação e Destroy ao final

O gateway usa long polling: a VM faz HTTPS de saída e não recebe webhook.

Destroy no Resource Manager antes de excluir a Stack

Da pasta baixada ao bot funcionando

FLUXO DO PARTICIPANTE




FOLDER PARA A STACK

`infra/terraform/oci-trial-deploy/dist/oci-hermes-resource-manager`

Quatro checkpoints evitam que dúvidas virem bloqueios

EVIDÊNCIA ANTES DE AVANÇAR

Mostre o resultado do passo atual antes de seguir para o próximo.



Falhou? Volte ao checkpoint anterior.

Sucesso: mensagem → Hermes → OCI Enterprise AI → resposta no Telegram.

Vamos para a Prática?


<https://h1.nu/1up2m>



RESULTADO DO WORKSHOP

Infraestrutura reproduzível · modelos governados · canal familiar

OCI + Hermes + Telegram
colocam o modelo em ação.



Obrigado!



www.linkedin.com/in/rafael-roberto-dias-data-lover/




Oracle Innovation Ecosystem.

Conectando pessoas, soluções e oportunidades.

Um ecossistema conectado para aprender,
construir, inovar e crescer com a **Oracle**.

Faça Parte!

Aprenda. Conecte-se. Desenvolva. Cresça.



Continue essa jornada.

Faça parte da comunidade oficial de desenvolvedores da Oracle e continue aprendendo, compartilhando e crescendo com quem está construindo o futuro da tecnologia.



Aprenda

Conteúdos exclusivos, workshops, labs e trilhas técnicas.



Conecte-se

Networking com especialistas e uma comunidade apaixonada por tecnologia.



Evolua

Eventos, certificações, mentorias e oportunidades para acelerar sua carreira.

Por que participar?



Eventos exclusivos



Certificações e badges



Mentorias com especialistas



Conteúdo técnico



Comunidade Oracle



Escaneie e **faça parte.**



Inscreva-se agora!

Oracle Innovators Club

Dados, Nuvem e IA.
Impulsionados pela
Comunidade.



Nossos programas para **desenvolvedores**.

Iniciativas que conectam, reconhecem e impulsionam
a comunidade de tecnologia Oracle.



Oracle **Innovators**
Club

 Aprenda.

 Conecte-se.

 Compartilhe.



Oracle
ACE
Program

 Reconhecimento.

 Influência.

 Comunidade.



Oracle
Java
Champions

 Excelência técnica.

 Liderança.

 Impacto global.



Oracle
Innovators
Podcast

 Conversas reais.

 Especialistas.

 Inovação.



Oracle
Analytics
and AI
Community

 Forums

 Ideas Labs

 Sharing Center

Um ecossistema conectado para **aprender, compartilhar conhecimento** e acelerar a **inovação**.





Seu feedback nos
ajuda a evoluir.

